

# REGRESSÃO LINEAR ESPACIAL

## O que é regressão linear?

A regressão linear é uma técnica de análise de dados que prevê o valor de dados desconhecidos usando outro valor de dados relacionado e conhecido. Ele modela matematicamente uma variável resposta (desconhecida ou dependente) e um conjunto de variáveis explicativas (preditoras, conhecidas ou independente) como uma equação linear:  $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ . Onde  $\mathbf{y} = (y_1, y_2, \dots, y_n)'$  é um vetor de medidas da variável resposta,  $\mathbf{X}$  é uma matriz com  $k$  variáveis explicativas,  $\boldsymbol{\beta} = (\beta_1, \beta_2, \dots, \beta_k)'$  é um vetor de coeficientes explicativos do modelo e  $\boldsymbol{\varepsilon} = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n)'$  é um vetor de erros do modelo. Matricialmente o modelo é representado por:

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{bmatrix} 1 & x_{12} & \cdots & x_{1k} \\ 1 & x_{22} & \ddots & x_{2k} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n2} & \cdots & x_{nk} \end{bmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

# REGRESSÃO LINEAR ESPACIAL

## Por que a regressão linear é importante?

Os modelos de regressão linear são relativamente simples e fornecem uma fórmula matemática fácil de interpretar para gerar previsões. A regressão linear é uma técnica estatística estabelecida e se aplica facilmente no R e em outros softwares. As empresas a utilizam para converter dados brutos de forma confiável e previsível em inteligência de negócios e insights práticos. Cientistas em muitos campos, incluindo saúde, biologia, ciências comportamentais, ambientais e sociais, usam a regressão linear para realizar análises preliminares de dados e prever tendências futuras. Muitos métodos de ciência de dados, como machine learning e inteligência artificial, usam a regressão linear para resolver problemas complexos.

## Etapas na regressão linear

1. Plotar uma linha e medir a correlação entre  $(x,y)$ .
2. Estimar os coeficientes da regressão.
3. Identificar a equação de regressão linear.
4. predizer valores para  $y$  para um valor ou vetor  $x$  de interesse

# REGRESSÃO LINEAR ESPACIAL

## Exemplo de regressão linear: PLANEJAMENTO DE PROPAGANDAS

considere que o proprietário de um estabelecimento deseja aumentar as vendas investindo em propaganda. Considere também que o gasto neste tipo de publicidade é calculado pelo número de inserções do anúncio na programação de rádio, tv e internet durante o mês. Com o cuidado de mensurar o efeito desses anúncios, o proprietário somou, ao final dos meses em que fez o investimento com o anúncio, o número de unidades vendidas. Uma amostra dos resultados obtidos dos últimos 10 meses está ilustrada a seguir:


unidades vendidas  $y = c(430, 335, 520, 490, 470, 210, 195, 270, 400, 480)$

Total de anúncios  $x = c(30, 21, 38, 42, 37, 20, 8, 17, 35, 25)$

Dispersão e correlação no R  
`plot(x,y)`  
`cor(x,y)`

$$\begin{pmatrix} 430 \\ 335 \\ \vdots \\ 480 \end{pmatrix} = \begin{bmatrix} 1 & 30 \\ 1 & 21 \\ \vdots & \vdots \\ 1 & 25 \end{bmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

**Qual é o valor dos coeficientes de explicação?  
Como interpretá-los? Qual é tamanho do erro ?**



# REGRESSÃO LINEAR ESPACIAL

Solucionando e interpretando o regressão linear no R:

```
modelo_linear <- lm(y ~ x)
```

```
summary(modelo_linear)
```

Call:

```
lm(formula = y ~ x)
```

Residuals:

Min	1Q	Median	3Q	Max
-99.775	-26.288	-1.325	21.921	122.126

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	117.377	55.695	2.108	0.068137 .
x	9.620	1.908	5.042	0.000999 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 62.36 on 8 degrees of freedom

Multiple R-squared: 0.7606, Adjusted R-squared: 0.7307

F-statistic: 25.42 on 1 and 8 DF, p-value: 0.0009992

Para cada 10 anúncio a mais, espera-se aumentar as vendas em  $9.62 \times 10 = 96$  unidades vendidas. Se não investir em anúncios, espera-se vender 117 unidades. O erro médio do Modelo é 62.36 com poder explicativo de 0.7307 (70,07%). Isto é, através dos anúncios conseguimos explicar 70,07% das variações nas vendas.

## Predição no modelo de regressão linear no R: $y_{\text{preditor}} = 117.38 + 9.62x$

```
amostra_teste <- data.frame(x=x)
```

```
y_predito <- predict(modelo_linear, amostra_teste)
```


```
y_predito
```

```
plot(x,y,xlab="Total de Anúncios",ylab="Unidades Vendidas",type="p",col="blue",pch=1,cex=1.5)
```

```
points(x,y_predito,type="p",col="red",pch=16)
```

```
legend(locator(1),c("y","y_predito"),pch=c(1,16),col=c("blue","red"))
```

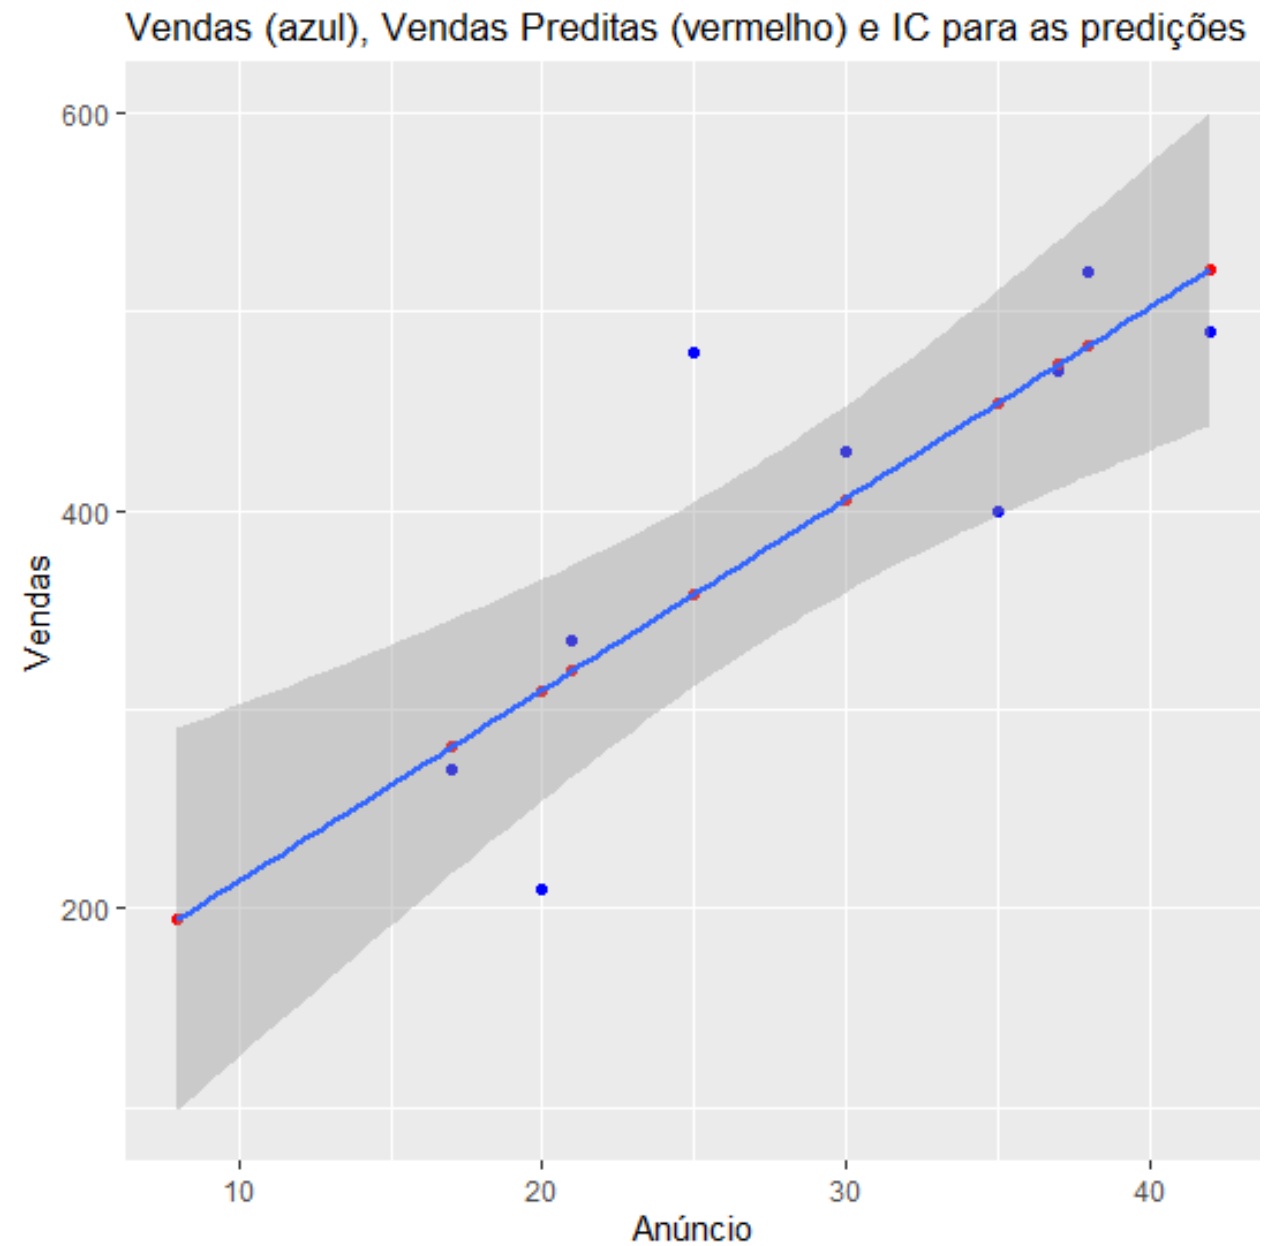
Mês	Vendas	Vendas preditas
1	430	405.9737
2	335	319.3947
3	520	482.9328
4	490	521.4123
5	470	473.3129
6	210	309.7748
7	195	194.3362
8	270	280.9152
9	400	454.0731
10	480	357.8743



## Plotando o Gráfico dos valores observados e Preditos para Vendas.

```
##--construindo um data.frame dos dados
ml <- data.frame(x=x, y=y, y_predito = y_predito)

##--plotando o grafico de vendas e preditos
ggplot(data=ml, aes(x=x, y=y, y_predito=y_predito)) +
  geom_point(aes(x=x, y=y), colour = "blue") +
  geom_point(aes(x=x, y=y_predito), colour = "red") +
  geom_smooth(method = "lm", formula = y ~ x) +
  labs(title = "Vendas (azul), Vendas Preditas (vermelho)
e IC para as predições", y = "Vendas", x = "Anúncio")
```



# REGRESSÃO LINEAR ESPACIAL

O que é regressão linear Espacial?

É um modelos de regressão que incorporam a dependência espacial nos dados através de uma estrutura de matriz de vizinhança. Os modelos mais usuais são:

Modelo SAR para dependência global (Spatial AutoRegressivo):  $y = \rho W y + X\beta + \varepsilon$ .

Modelo CAR para dependência global (Condicional AutoRegressivo):

$E(y | y_{[-i]}) = X\beta + \rho W(y - X\beta)$ , W é a matriz Binária linha padronizada

Modelo de Regressão Ponderada (GWR - Geographically Weighted Regression):

$y(s) = X\beta(s) + \varepsilon$ , um beta para cada local s dado por:  $\beta(s) = (X'W(s)X)^{-1}X'W(s)y$

A AULA CONTINUA NO ARQUIVO: regressão\_espacial\_doctor

# Conclusão da Obra de Hoje!

A partir da análise de regressão espacial, Modelos SAR, CAR e GWR, além da análise do correlograma de Moran para o resíduo da regressão usual, foi possível identificar um padrão de dependência de 1ª ordem local para os casos de leucemia em NY8 1978-1982, sendo o modelo CAR o mais adequado com menor AIC. O uso da inteligência espacial nos evidenciou que o padrão de casos foi alterado após o ajuste por variáveis preditoras. Após uma análise minuciosa, percebemos através do Modelo CAR que o fator de exposição (proximidade da fonte TCE) foi o que mais influenciou o número de casos. Por fim, o gráfico de valores observado pelo ajustado e resíduos ajustados versus a predição evidenciaram visualmente um bom ajuste do modelo CAR estimado o qual foi utilizado para elaboração do mapa da predição de riscos relativos de casos, permitindo assim, identificar distritos isolados de alto risco.





# PERGUNTAS?

- Obrigado !